

Fraud Prevention

LUCAS ESQUIVEL

OBJETIVOS

Una entidad financiera nos proveyó de datos transaccionales de todo un año calendario de su cartera de clientes y nos encomendó la tarea de analizarlos para ayudarlos a definir en conjunto criterios que califiquen a una transacción como potencialmente sospechosa. Luego nos pidieron que desarrolláramos un modelo en base a este criterio para predecir si las futuras transacciones son potencialmente sospechosas o no.

01

Exploramos y analizamos el set de datos

02

Definimos los criterios que clasifican a una transacción como sospechosa

03

Desarrollo y evaluación del modelo tomando la variable (ClienteSospechoso) como variable target.

04

Conclusión Final y Recomendaciones.


01 EXPLORAMOS Y ANALIZAMOS LOS DATOS

	TransactionAmount	TransactionDate	CustomerAge	TransactionDuration	LoginAttempts	AccountBalance
count	2512.000000	2512	2512.000000	2512.000000	2512.000000	2512.000000
mean	297.593778	2023-07-05 20:32:10.826433024	44.673965	119.643312	1.124602	5114.302966
min	0.260000	2023-01-02 16:00:06	18.000000	10.000000	1.000000	101.250000
25%	81.885000	2023-04-03 16:22:05.750000128	27.000000	63.000000	1.000000	1504.370000
50%	211.140000	2023-07-07 17:49:43.500000	45.000000	112.500000	1.000000	4735.510000
75%	414.527500	2023-10-06 18:40:53.500000	59.000000	161.000000	1.000000	7678.820000
max	1919.110000	2024-01-01 18:21:50	80.000000	300.000000	5.000000	14977.990000
std	291.946243	NaN	17.792198	69.963757	0.602662	3900.942499

01 EXPLORAMOS Y ANALIZAMOS LOS DATOS

- Vemos que la desviación estándar del **TransactionAmount** es casi idéntico al promedio, por lo que podemos decir que hay una gran dispersión, o sea valores alejados de la media. Además también podemos ver que los valores máximo y mínimo están muy alejados del promedio lo que también nos indica que hay outliers o valores atípicos, eso podría indicar movimientos sospechosos.
- Siguiendo con la **edad** de los clientes vemos que el promedio está en los 45 años, la edad mínima está en 18 y el máximo en 80, lo cual nos indica que tenemos una buena variedad rangos etarios, esto nos servirá para analizar el comportamiento transaccional según la edad y poder hacer comparaciones entre los mismos.
- En cuanto a la **TransactionDuration** vemos que hay mucha diferencia entre el cuartil 75% que es de 161 y el máximo valor que es de 300 minutos. Duraciones más largas podrían indicar actividad fraudulenta.
- Mismo caso con **LoginAttempts (intentos de login)**, vemos que hasta el 75% de la muestra la cantidad de intentos es 1, pero vemos que el máximo es 5, también podría estar indicando algún indicio de actividad sospechosa.
- En cuanto al **AccountBalance (saldo de la cuenta)** podemos decir que hay cuentas que tienen saldos muy pequeños (min= 100USD vs max= 15.000USD) esto podría servirnos para analizar el comportamiento entre cuentas que tienen bajos saldos vs las que tienen altos saldos, cantidad de transacciones, ubicación geográfica, rango etario, ocupación, etc.

01 EXPLORAMOS Y ANALIZAMOS LOS DATOS



Relación entre Edad, Balance de la cuenta y Monto de las transacciones

En este caso mediante scatterplots o gráficos de dispersión, podemos visualizar que hay una clara concentración de casos de clientes de entre 18 y 30 años que los balances de sus cuentas no superan los USD2000. Con esta referencia si pasamos al tercer scatterplot podemos decir que si vemos clientes con ese rango etario con transacciones de mas de USD1000 deberíamos tomarlas como dudosas. Asi mismo cuando vemos la relacion entre balance y monto de la transaccion vemos que la mayoría de las transacciones tienen un monto menor a UDS1000.

02 DEFINIMOS LOS CRITERIOS QUE CLASIFICAN A UNA TRANSACCION COMO SOSPECHOSA

Según el análisis que acabamos de hacer sobre las variables numéricas, y luego de haber alineado el criterio en conjunto con el negocio podemos considerar casos potencialmente sospechosos si cumplen con al menos uno de las siguientes condiciones:

- * Edad entre 18 y 31 años con un monto de transacción mayor o igual a USD1000.
- * Duración de la transacción de más de 160 minutos
- * Más de 1 intento de login
- * Cuentas con balances de menos de USD2000 y montos de transacción superiores a USD500


El resultado de esta segmentación será una variable binaria que tomará el valor de 1 cuando el cliente sea potencialmente sospechoso y 0 cuando sea no sospechoso.

03 DESARROLLO Y EVALUACIÓN DEL MODELO TOMANDO LA VARIABLE (CLIENTESOSPECHOSO) COMO VARIABLE TARGET.

- Decidimos desarrollar un modelo de árboles de decisión (Decision Trees) ya que es un modelo de clasificación supervisado que creemos que puede ayudarnos a resolver nuestra necesidad.

- Estos Fueron los Resultados:

```
Accuracy: 0.99  
Precision: 1.00  
Recall: 0.99  
F1 Score: 0.99  
Confusion Matrix:  
[[513  1]  
 [  3 237]]
```



Vemos que el accuracy es del 99%. Lejos de ser bueno, claramente estamos ante un caso de sobreajuste. Vemos también que en la matriz de confusión casi el 100% de los casos son predichos correctamente, lo cual nos indica que este modelo es muy bueno sobre los datos que tenemos hoy en día para entrenar y testear el modelo pero difícilmente tenga buena performance con datos nuevos. Habría que probar datos nuevos para entender si la efectividad es tan buena o si es un caso de sobreajuste.

Además vemos que una sola variable explica la mayor parte del modelo, lo cual indica un potencial sesgo.

04 CONCLUSIÓN FINAL Y RECOMENDACIONES.

Lamentablemente, si bien los resultados del modelo son excepcionales, no podemos confiar en que esa predicción sea efectiva ya que lo más probable es que esté sobreajustando y que tenga una muy mala performance cuando lo pasemos a producción. Mi recomendación es, buscar más datos para tener otros datos distintos de entrenamiento y testeo o ajustar el criterio de "Cliente Sospechoso" porque puede ser que nos esté quedando corto ese criterio.

The background is a solid dark blue. It is decorated with several abstract, light blue geometric shapes. On the left side, there are three shapes: a parallelogram at the top, a trapezoid in the middle, and a triangle at the bottom. On the right side, there are four shapes: a trapezoid at the top, a parallelogram below it, and two more trapezoids at the bottom, one slightly overlapping the other.

Gracias!